

Final Demo Full Recording Script (Chinese)

这份讲稿给负责录制 demo 视频的同学使用。当前版本按 3 分钟展示压缩，录制时以浏览器里的 Web UI 为主，不需要展示太多命令行和文件目录。

0. 录制前准备

在仓库根目录运行：

```
python -m uvicorn demo_web.app:app --host 127.0.0.1 --port 8000
```

然后浏览器打开：

```
http://127.0.0.1:8000/
```

提前准备好 CSV 文件：

```
final_docs/execution_evidence/sample_requirement_batch.csv
```

录制时只使用页面里的 **mock** provider。这里的 **mock** 是为了保证演示稳定；正式实验质量来自 frozen formal results 和 replay，不来自临时 ad hoc mock。

1. 三分钟录制流程

0:00 - 0:08 开场

操作：浏览器停留在 Web UI 首页。

口播一句话：

大家好，这里用三分钟展示 ARG-Test 如何把自然语言 requirement 转换成结构化、可审计、可 replay 的测试设计结果。

0:08 - 0:55 Output Preview / Direct Input

操作：

1. 点击 **Direct Input**。
2. Requirement Case 选择 **pickup_station_contact_validation**。
3. 保持 provider 为 **mock**，不要改 requirement 文本。
4. 点击 **Generate Test Suite**。
5. 结果出现后，看右侧 **Output Preview / Generated Suite and Diagnostics**。

发言稿：

第一步看 Output Preview。这里我选择一个正式 test split 中的 input validation requirement，然后点击生成。页面右侧可以看到 **Structural Checker = 0.950**，**Overall Coverage = 71.3%**，并且 **Run Mode** 是 **Replay**。

重点是 **Result Source** 这里标注了 **Frozen formal replay**、**Matches Formal Evidence coverage** 和 **No live API call**。也就是说，这个正式样例不是现场随机 mock 出来的，而是回放冻结的 formal result，因此页面数字和最终报告中的正式结果是一致的。

下面还能看到 risk assessment、recommended focus 和 generated test cases。它不是普通 prompt 文本，而是包含测试数据、expected output、技术类型和诊断信息的结构化输出。

0:55 - 1:30 CSV Batch

操作：

1. 点击 **CSV Batch**。
2. 上传 **final_docs/execution_evidence/sample_requirement_batch.csv**。
3. 点击 **Run Batch Analysis**。
4. 结果出现后看 **Batch Output / Requirement-Level Summary**。

发言稿：

第二步展示 CSV Batch。这个入口说明系统不仅能处理单条 requirement，也能批量导入 CSV。

运行后，结果区域会显示 batch size 和每条 requirement 的 compact result card，包括 category、structural score、coverage、risk 和 source。匹配正式 requirement 的行会显示 **Frozen replay**，表示它同样来自冻结正式结果；如果是临时改写的 ad hoc CSV，则只能作为功能演示，不能当成正式 benchmark。

1:30 - 2:15 State Model

操作：

1. 点击 **State Model**。
2. Workflow Case 选择 **warehouse_pickup_order_workflow**。
3. 不改文本内容。
4. 点击 **Build State Model**。

5. 结果出现后看 states、legal transitions、illegal transitions 和 coverage plans。

发言稿：

第三步展示 State Model，这对应 final requirement 里的 **FR 4.0**。我们选择 **warehouse_pickup_order_workflow**，点击构建状态模型。

页面显示这个 workflow 被抽取出了 **5** 个 states、**4** 条 legal transitions、**2** 条 illegal transitions 和 **2** 个 coverage plans。下面的表格展示了合法迁移和非法迁移，例如订单可以从 **READY_FOR_PICKUP** 到 **PICKED_UP**，但 **PICKED_UP** 回到 **READY_FOR_PICKUP** 会被识别为 illegal transition。

这里要注意，如果某个 requirement 没有显式非法迁移规则，illegal transitions 为 **0** 是合理的，不代表功能失败。

2:15 - 2:52 Formal Evidence

操作：

1. 点击 **Formal Evidence**。
2. 看顶部指标卡：**Official Test Requirements**、**Avg Structural Checker**、**Avg Overall Coverage**、**Avg Test Count**。
3. 快速扫一下 Baselines、Category Generalization、Reproducibility Snapshot。

发言稿：

最后看 Formal Evidence，这是最终报告、PPT 和答辩中最安全的正式数字来源。

这里显示 held-out test split 一共有 **16** 个 requirements，平均 **Structural Checker = 0.959**，平均 **Overall Coverage = 61.5%**，平均 test count 是 **7.312**。下面还有 baseline comparison、category generalization 和 reproducibility snapshot。

所以前面的 Direct、CSV 和 State Model 证明工具可以交互运行，而这里的 Formal Evidence 证明最终质量数字来自 frozen formal snapshot，不依赖现场 live API。

2:52 - 3:00 结束

操作：停在 **Formal Evidence** 页面即可。

口播一句话：

总的来说，ARG-Test 不只是一个 prompt demo，而是一个有结构化输出、风险与状态建模、冻结结果 replay 和正式实验支撑的 AutoTestDesign 工具。

2. 录制时不要说错的边界

下面这些不是口播正文，但录制时必须注意：

- 不要说我们训练或微调了 LLM。
- 不要说 rule-based baseline 来自某篇论文或开源系统；它是我们自己实现的 deterministic heuristic baseline。
- 不要说 live provider 完全 deterministic。
- 不要把 **checker_score** 说成 correctness；它是 structural contract consistency。
- 不要把临时修改 requirement 后生成的 ad hoc mock 结果说成正式 benchmark。
- 不要展示 **.env**、API key、长 JSON 或无关本地目录。